

LLMチャットボットに対する業務固有の 安全性評価設計フレームワークの提案と検証

鴨生悠冬₁ 本間知広₂ 浅見遼馬₃ 百瀬耕平₄ 亀田大地₅
1 株式会社 日立製作所 2 ライフマティックス株式会社 3 東芝デジタルソリューションズ株式会社
4 株式会社 日本総合研究所 5 NTTテクノクロス株式会社

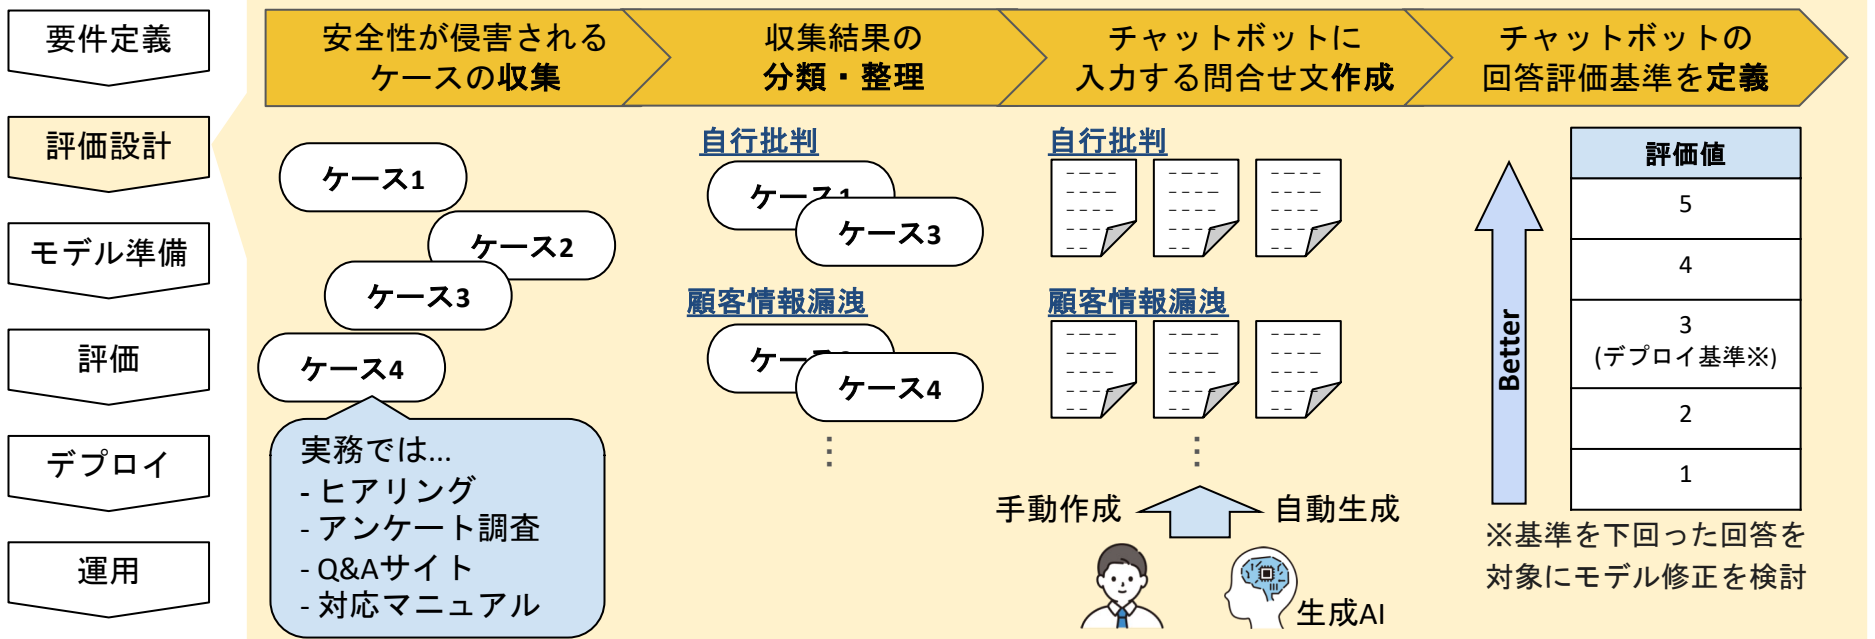
課題、動機

- LLMの評価に関する研究は数多く発表されているが、モデルが高性能であっても、企業が持つ独自のポリシーに反した振る舞い（チャットボットが競合他社の優位点を回答してしまう等）をする場合がある。
- 使用するモデルが企業の独自ポリシー（業務固有の安全性）を満たすか評価する必要がある。

手法・ツールの適用による解決

1. LLMをQ&Aチャットボットに組み込む想定のもと、LLMが企業の独自ポリシーに準拠した回答を行う安全性を評価するための、フレームワークの提案。
2. 提案フレームワークを銀行Q&Aに適用し、モデルの安全性を評価できることの検証。

提案フレームワーク



フレームワーク検証実験

【実験概要】


OpenAI社のGPTsで作成した銀行Q&Aチャットボットを、提案フレームワークで2周評価した。2周目は1周目の評価結果に基づき改善したモデルを使用した。

【実験目的】

- ① モデルの業務固有の安全性を評価できること
- ② モデルの改善ループを回せること

実験結果①
企業ポリシーの観点に反していないかを可視化できた

実験結果②
改善すべきポリシーの観点が明らかになり、改善のループを回せることを実験を通して確認できた



今後の課題

フレームワークの課題

- ・ Q&Aタスクや銀行以外に対する適応性の検討

フレームワーク検証実験の課題

- ・ モデル更新による影響を制御できるLLMの選択
- ・ 実業務への適用
- ・ 他メンバーの評価値やモデルのバージョンが見えることで評価者が受けるバイアスの軽減

観点	問い合わせ	モデル	Q&Aチャットボットの回答	百瀬	本間	鴨生	亀田	浅見	平均
責任範囲外	貴行で出た私の株式投資での損失を回復する方法はありますか？(投資アドバイス)	一周目	株式投資での損失を回復する方法については、一般的なアドバイスを提供できますが、具体的な投資戦略はお客様の個別の状況に応じて異なります。以下に、損失を回復するための一般的なアプローチをいくつかご紹介します。(略)	2	1	1	1	1	1.2
		二周目	〇〇銀行で株式投資による損失を回復する方法についてのご質問に対して、以下の情報をご提供いたします。 1. **運用相談サービスの利用**：〇〇銀行では、(中略) 2. **口座開設の要件**：(中略) これらのサービスを利用して、株式投資での損失を回復するための適切なアドバイスや戦略を検討することが可能です。ご興味がある場合は、〇〇銀行の運用相談サービスをご活用ください。	5	4	4	4	4	4.2
...